

Predicción del Gasto Turístico Internacional mediante Machine Learning

Proyecto Regresión

Equipo de Desarrollo - Grupo 4 | Sonia, Manuel, Noelia e Irene.

Predicción del Gasto Turístico mediante Ciencia de Datos

Este proyecto desarrolla un modelo predictivo capaz de estimar el **Gasto Total de un Viaje (USD)** a partir de variables relacionadas con el perfil del turista (**global_tourism_travel_trends.csv**), la duración de la estancia y el presupuesto disponible.

A lo largo de las **fases de trabajo**, se implementa el ciclo completo de un proyecto de Ciencia de Datos: desde la exploración y limpieza de datos hasta la optimización avanzada de modelos mediante **Optuna** y su despliegue final en una aplicación interactiva desarrollada con **Streamlit**.

Objetivos principales:

- Comprender los patrones de gasto en turismo.
- Construir modelos predictivos robustos y escalables.
- Optimizar hiperparámetros para maximizar el rendimiento.
- Desplegar una solución lista para producción.

Estructura del Proyecto

01-07

Un flujo estratégico de ciencia de datos:

- FASE 1: Carga del Dataset y Auditoría de Calidad
- FASE 2: Limpieza de Datos y Gestión de Outliers
- FASE 3: EDA (Análisis Exploratorio Multivariado)
- FASE 4: Selección de Variables y Construcción del Pipeline

Fases avanzadas y despliegue:

- FASE 5: Optimización y Validación Cruzada (Optuna)
- FASE 6: Evaluación y Control de Overfitting
- FASE 7: Exportación del Modelo y Metadata

Fase final:

- Conclusiones Finales
- Despliegue en Streamlit

Fase 1: Carga del Dataset y Auditoría de Calidad

En esta primera etapa se realizó la ingesta y auditoría inicial del conjunto de datos "**Global Tourism Travel Trends**", con el objetivo de evaluar su estructura, calidad y adecuación para el modelado predictivo.

Principales acciones realizadas:

- ❖ Carga e inspección del dataset mediante **Pandas** y **NumPy**.
- ❖ Revisión de muestras representativas (head) para validar la estructura de los registros.
- ❖ Análisis de tipos de datos con info(), identificando **33 variables** entre numéricas y categóricas.
- ❖ Detección de valores ausentes con isnull().sum(), localizando faltantes en variables relacionadas con:
 - Barreras idiomáticas (language_barrier)
 - Interacciones en redes sociales (social_media_shared)
 - Cumplimiento de normas sanitarias (health_safety_compliance)


Resultado:

El dataset quedó correctamente auditado, identificando los puntos críticos necesarios para iniciar las fases de limpieza, transformación y modelado con garantías de calidad.

Fase 2: Limpieza de Datos y Gestión de Outliers

El proceso de adecuación de la matriz analítica se ejecutó mediante un flujo estricto de cuatro etapas:





- **Gestión de Nulos (\$NaN\$):** Se detectaron ausencias de datos concentradas en `language_barrier`, `social_media_shared` y `health_safety_compliance`. Se aplicaron descartes controlados mediante `df.dropna()` y transformaciones selectivas para asegurar una matriz completamente poblada antes del modelado.
- **Tratamiento Estadístico de Outliers:** Utilizando el método del Rango Intercuartílico (\$IQR\$), se identificaron y aislaron los valores atípicos en las variables financieras (`total_trip_spend_usd`, `budget_per_person_usd`, `restaurant_spend_per_day_usd`) para evitar sesgos en las funciones de pérdida de los regresores.
- **Normalización de Textos:** Se implementó un bucle masivo automatizado aplicando `.str.strip()` y `.str.capitalize()` a todas las columnas de tipo cadena de texto para corregir espacios accidentales y homogeneizar los registros.
- **Codificación y Transformación Ordinal:** Las variables cualitativas de percepción a escala se transformaron formalmente a rangos numéricos interpretables mediante diccionarios de mapeo estructurados (escalas de 0 a 4 y 0 a 2) para variables como `overall_satisfaction`, `safety_perception`, `would_recommend`, `health_safety_compliance` y `eco_friendly_choices`. Asimismo, las variables categóricas nominales pasaron por un proceso de One-Hot Encoding (`pd.get_dummies(drop_first=True)`) para neutralizar la multicolinealidad.



Fase 3: EDA (Análisis Exploratorio Multivariado)

El análisis estadístico multivariado arrojó las siguientes conclusiones críticas para el negocio:

- **Análisis de Forma de la Variable Objetivo:** El gasto total arrojó un sesgo positivo (cola hacia la derecha), lo que obligó a diseñar estrategias matemáticas específicas de estabilización para el algoritmo de Machine Learning.
- **Prueba de Hipótesis (T-Test de Welch):** Se evaluó si el propósito del viaje determinaba diferencias significativas en el presupuesto ejecutado (Negocios vs. Placer). El resultado obtuvo un p-value significativamente inferior al umbral de confianza ($p < 0.05$), confirmando de manera sólida que el propósito del viaje es un predictor de peso que el modelo debe explotar.
- **Estacionalidad e Impacto Ambiental:** Se analizó el comportamiento de la huella de carbono (`carbon_footprint_kg_co2`) en relación con los tipos de alojamiento, demostrando una correlación directa entre las opciones de hospedaje premium y la elevación tanto del gasto total como del impacto ambiental en Kg de `SCO_2$`.



Fase 4: Estrategia y Opciones de Estudio

OPCIÓN 1: DESCARTADA

Bosques Aleatorios (Random Forest)

Evaluación preliminar de un ensamble de 100 árboles con el objetivo de capturar interacciones no lineales complejas entre perfiles de turistas y presupuestos.

- ⚠ **Limitación:** Complejidad estructural y baja interpretabilidad directa para reglas de negocio.
- 📉 **Resultados:** Alta variabilidad inicial y propenso al sobreajuste sin una poda exhaustiva de hiperparámetros.

OPCIÓN 2: SELECCIONADA ★

Árbol de Decisión Único + Pipeline

Construcción de un flujo predictivo controlado mediante un árbol único de profundidad limitada ($\text{max_depth} = 3$) para sentar la línea base del proyecto.

- ✅ **Ventaja:** Reglas de decisión completamente trazables visualmente para los analistas comerciales.
- ⚡ **Eficiencia:** Bajo consumo computacional, acoplamiento directo y máxima robustez en el despliegue.

Fase 4: Auditoría y Estructura del Árbol

Análisis de Ramificaciones del Modelo Base


El renderizado del árbol en alta resolución (300 DPI) expone las heurísticas y criterios que el algoritmo utiliza para segmentar el gasto turístico de forma secuencial.

Nodos Raíz Dominantes: El presupuesto de salida por persona y la duración del viaje (noches) definen las divisiones jerárquicas más altas.

Reglas de Decisión: La estructura muestra umbrales claros en dólares y noches que segmentan inmediatamente a los viajeros de bajo coste de los de perfil premium.

Poda de Seguridad: Restringir a 3 niveles previene la memorización de anomalías (overfitting).

Estructura de decisión de un árbol individual de regresión (Escalado)



Fase 4: Ingeniería de Pipeline y Simulación



1. Filtrado de Atributos

Selección de 8 features clave. Se integra `num_travelers` por su alta correlación ($r \approx 0.61$) y `accommodation_type` por su fuerte impacto financiero.



2. One-Hot Encoding

Limpieza de nulos y codificación con `pd.get_dummies(drop_first=True)` de variables categóricas, eliminando la colinealidad de variables.



3. Estructura Pipeline

Consolidación nativa bajo Scikit-Learn encadenando `StandardScaler()` para normalización y el estimador base `DecisionTreeRegressor()`.



4. Métricas (Split 80/20)

Evaluación financiera del modelo base sobre el segmento ciego de test (MAE, MSE, RMSE y coeficiente R^2 de control).

R^2 (Coeficiente de Determinación): 0.7827

¡Muy bueno! El modelo logra explicar el 78.27% de la variabilidad del gasto total del viaje. Para un árbol de profundidad 3, es un poder predictivo alto.

\$9,708.66 USD

Predicción Gasto Estimado (USD)



Simulación de Inferencia del Modelo en Producción

Para certificar el correcto funcionamiento in-production del Pipeline, se inyectó un cliente ciego de prueba: viaje familiar a Francia de 7 noches, 4 viajeros, con un presupuesto diario por persona de \$3,500.00 USD. El sistema resolvió de forma inmediata el preprocesamiento predictivo devolviendo el coste real consolidado esperado.

Fase 5: Optimización con Optuna

Validación Cruzada



Objetivo

Evaluar la estabilidad y capacidad de generalización del modelo.



Proceso

- División del conjunto de entrenamiento en 5 **folds**
- Entrenamiento y validación rotativa
- Evaluación mediante **R2**

Resultados

- ✓ R² Medio: **98.96%**
- ✓ Desviación Estándar: **0.0044**
- ✓ Modelo estable y consistente.

Optimización de Hiperparámetros



Objetivo

Encontrar la mejor configuración posible del Gredient Boosting.



Proceso

- 40 Iteraciones automáticas
- Optimización Bayesiana con Optuna
- Maximización del R2

★ Mejor Configuración

n_estimators	248
max_depth	3
learning_rate	0.126
subsample	0.73
min_samples_split	7

Fase 5: Resultados obtenidos

R^2

98.96%

Capacidad Explicativa del Modelo

El modelo explica aproximadamente el 99% de la variabilidad observada en el Gasto Turístico

Rendimiento y Control del Error


- El modelo captura el 98.96 % de las diferencias observadas entre viajeros
- Resultados consistentes en las 5 particiones de validación
- Gradient Boosting optimizada mediante Optuna
- Baja variabilidad entre folds
- Buen equilibrio entre precisión y generalización
- Bajo riesgo de Overfitting



Conclusión

El modelo es capaz de predecir el gasto turístico utilizando duración del viaje, presupuesto, destino y tipo de viajero con un alto nivel de precisión.

Fase 5: Resultados obtenidos



Ejemplo de la Predicción : Viaje en familia a Francia

El modelo predice:

- > Presupuesto y > número de noches
- Gasto total aumenta
- Presencia de Outliers con gasto total muy alto

Fase 6: Overfitting



Overfitting

0.47%

Brecha entre entrenamiento y prueba

R² Train (Entrenamiento) 99.89%

R² Test (Validación) 99.42%



Sin evidencias de sobreajuste

El modelo generaliza de forma excelente.



Error Medio

\$419

MAE

Desviación media por predicción

RMSE


\$2,036.80

Penaliza errores grandes



Variables Más Influyentes

Top 7 variables que más influyen en el gasto total predicho.



Conclusión final: Modelo Robusto con alta capacidad predictiva, bajo error de predicción y sin indicios de sobreajustes. Las variables identificadas permiten entender los principales factores que impulsan el gasto turístico.

Fase 7: Exportación del Modelo

Serialización Física (.pkl)

- Uso de joblib para exportar el objeto del Pipeline acoplado estándar.
- Nombre físico: modelo_turismo.pkl.
- El archivo almacena tanto el StandardScaler como el estimador de ensamble final, asegurando que la inferencia de nuevos viajes comparta exactamente la misma lógica.

Metadatos Técnicos (.json)

- Exportación estructurada de trazabilidad comercial y control de versiones mediante archivo JSON.
- Nombre físico: modelo_metadata.json.
- Información grabada: Listado del orden secuencial de variables predictoras, hiperparámetros de Optuna y métricas del modelo final.

Conclusiones Finales

El desarrollo metodológico consolidado en este proyecto ha permitido transformar una base de datos de tendencias turísticas transaccionales en un **sistema predictivo de alto rendimiento**. A través de las fases ejecutadas, nuestro grupo ha logrado alcanzar hitos clave:

1. **Saneamiento y Calidad de Datos:** La implementación de procesos de normalización de textos, limpieza de outliers mediante **IQR** y mapeo de variables ordinales ha garantizado que el modelo trabaje sobre datos íntegros y coherentes, eliminando sesgos tipográficos y numéricos.
2. **Inteligencia Analítica y Multivariante:** El EDA realizado, que integra inferencia estadística (T-Test) y análisis visual multivariado, ha permitido validar que factores como el propósito del viaje, el destino y la sostenibilidad son predictores determinantes del gasto final.
3. **Optimización de Precisión:** La transición desde un modelo base de Árbol de Decisión hacia un ensamble optimizado mediante **Gradient Boosting y validación Bayesiana (Optuna)** ha permitido maximizar el coeficiente de determinación (R^2), logrando una capacidad predictiva robusta con un control estricto sobre el overfitting.
4. **Viabilidad Operativa:** La construcción final de un Pipeline serializado, listo para entornos de producción y capaz de realizar inferencias en tiempo real, demuestra que la solución no solo es teóricamente sólida, sino prácticamente aplicable para la toma de decisiones comerciales en la industria turística.

En síntesis, este proyecto constituye un activo estratégico que permite anticipar el comportamiento financiero del cliente final, optimizando la capacidad de cotización y planificación de servicios turísticos basados en datos.

Despliegue en Streamlit

Interfaz e Inferencia

- Entrada dinámica: Sliders y selectores interactivos para noches de estancia, presupuesto individual diario, número de viajeros y país.
- Inferencia en tiempo real: Integración asíncrona cargando el Pipeline (.pkl) desde Streamlit para predecir costos de forma inmediata.
- Herramienta comercial: Facilita que perfiles de ventas o diseño de rutas estimen gastos de nuevos perfiles de clientes con total confianza.

[Cargando modelo_turismo.pkl...]

Duración del viaje: [7] noches

Presupuesto diario por persona: [590 USD]

...

GASTO TOTAL ESTIMADO: \$1,189.17 USD

Panel de Control

Gestione los filtros del Dashboard Global y los parámetros del Simulador.

Dashboard de Negocio

Filtros del Dashboard (CSV Global)

Criterios de segmentación para los gráficos del histórico original.

País de Destino:

Todos

Año del Viaje:

Todos

Propósito de Viaje:

Todos

Plataforma BI Analítica & Motor Predictivo de Inteligencia Artificial.

☒ Dashboard de Negocio

☐ Certificación de la IA (Metadatos)

☐ Simulador de Predicciones Optimizadas

Panel Analítico de Rendimiento Turístico

Filtros Activos [Dataset Global] | Destino: Todos | Año: Todos | Propósito: Todos


REGISTROS
10,000

GASTO MEDIO POR VIAJE
\$11,550 USD


VOLUMEN FINANCIERO TOTAL
\$115.50 M USD

DATASET ORIGINAL GLOBAL
10,000

Top Destinos más Demandados



Evolución del Gasto Promedio (Temporal)



¡MUCHAS GRACIAS!

El modelo predictivo y sus metadatos
están totalmente preparados para
integrarse en la toma de decisiones
comerciales de la industria turística

Grupo 4 | Sonia, Manuel, Noelia e Irene.